

KI-MODELLE IM VERGLEICH – WELCHES MODELL FÜR WELCHE AUFGABE?

KI-Modelle im Vergleich

Welches Modell eignet sich für welche Aufgabe?

Eine praxisorientierte Übersicht für KI-Anwendungen

Stand: 17. Juli 2026

Inhalte im Überblick

01 Lernziele

03 Text zu Tokens – grobe Orientierung

05 Input und Output

02 Was sind Tokens?

04 Dokumente im Vergleich

06 Aktueller Modellstand

Das nehmen Sie aus diesem Modul mit

1

VERSTEHEN

Die wichtigsten Inhalte des Moduls sicher erklären

2

ANWENDEN

Das Wissen auf einen konkreten Praxisfall übertragen

3

PRÜFEN

Ergebnisse kritisch bewerten und nächste Schritte ableiten

Lernziele

1

TOKENS

Input und Output erklären



2

KOSTEN

API-Kosten überschlägig berechnen



3

MODELLE

Qualität, Latenz und Kosten einordnen



4

ROUTING

Einen mehrstufigen Modell-Router skizzieren

Was sind Tokens?

01 Ein Token ist eine Verarbeitungseinheit eines Sprachmodells.

02 Ein Token entspricht nicht zuverlässig einem Wort: Es kann ein Wort, Wortfragment, Satzzeichen oder anderes Zeichenmuster abbilden.

03 Tokenisierung hängt von Sprache, Modellfamilie und Tokenizer ab. Deshalb sind Seiten- und Wortangaben immer Näherungswerte.

Text zu Tokens – grobe Orientierung

1–2

„Hallo“

2–4

„Guten Morgen“

700–900

1 DIN-A4-Textseite

1.100–1.400

Textseiten je 1 Mio. Tokens

Dokumente im Vergleich

DOKUMENT	PLANUNGSANNAHME
Kurze E-Mail	≈ 150 Tokens
Brief	≈ 500 Tokens
Vertrag, 30 Seiten	≈ 25.000 Tokens
Bauvertrag, 300 Seiten	≈ 180.000–250.000 Tokens
Fachbuch, 300 Seiten	≈ 220.000–300.000 Tokens

Input und Output

INPUT – WAS GESENDET WIRD

A

Prompts · Dokumenttexte · PDFs · OCR-Texte ·
Bilder · Verlauf · Tool-Ergebnisse



OUTPUT – WAS DAS MODELL ERZEUGT

B

Antworten · Analysen · Tabellen · Berichte ·
Zusammenfassungen · Tool-Aufrufe

Aktueller Modellstand

OPENAI

01

GPT-5.6 ist seit 9. Juli 2026 die aktuelle Familie: Sol, Terra und Luna. GPT-5.5 bleibt ein Vorgänger, ist aber nicht mehr die aktuelle Referenz.

ANTHROPIC

02

Fable 5, Opus 4.8, Sonnet 5 und Haiku 4.5 bilden unterschiedliche Qualitäts-, Latenz- und Kostenklassen.

**MODELLNAMEN, PREISE UND
VERFÜGBARKEIT VOR
PRODUKTIVEM EINSATZ ERNEUT
PRÜFEN.**

03

OpenAI API Preise



Claude API Preise



Prompt-Caching richtig einordnen

01 Bei wiederkehrenden langen Prompt-Präfixen können Cache-Treffer Inputkosten deutlich reduzieren.

02 • Cache-Lesezugriffe sind häufig etwa 90 % günstiger als normaler Input

- Cache-Schreibvorgänge werden separat beziehungsweise mit Aufschlag berechnet
 - nur tatsächlich wiederverwendete Präfixe profitieren
 - Cache-Rate, Mindestlänge und Lebensdauer sind anbieterspezifisch
-

03 Caching ist eine Architekturentscheidung – kein pauschaler Rabatt auf alle Eingaben.

Kostenbeispiel: großer Bauvertrag

01 Annahme pro Analyse

250.000 Input-Tokens + 5.000 Output-Tokens, ohne Cache und Tools

02 GPT-5.6 Sol $\approx$ \$1,40

GPT-5.6 Terra $\approx$ \$0,70

GPT-5.6 Luna $\approx$ \$0,28

Claude Fable 5 $\approx$ \$2,75

Claude Opus 4.8 $\approx$ \$1,38

Claude Sonnet 5 $\approx$ \$0,55 Einführung / \$0,83 Standard

Claude Haiku 4.5 $\approx$ \$0,28

Keine Sternchen ohne eigene Evals

EIGENE TESTFÄLLE

A

OCR · Baupläne · Handschrift · Verträge ·
Leistungsverzeichnisse



MESSGRÖSSEN

B

Korrektheit · Belegtreue · strukturierte Ausgabe ·
Latenz · Kosten · Stabilität

Kandidaten nach Aufgabenklasse

HOHES VOLUMEN

GPT-5.6 Luna oder Claude Haiku 4.5

DOKUMENTE & BALANCE

GPT-5.6 Terra oder Claude Sonnet 5

KOMPLEXE ANALYSE

GPT-5.6 Sol oder Claude Opus 4.8

HÖCHSTE FÄHIGKEIT

Claude Fable 5 oder GPT-5.6 Sol

Kandidaten nach Aufgabenklasse

Vision, OCR und Baupläne

PRÜFFELDER

A

- gedruckter Text und Handschrift
- Tabellenstruktur und Positionsbezüge
- Planlegenden, Maße und räumliche Beziehungen



TESTDESIGN

B

- mehrseitige Konsistenz
- Verweise zwischen Bild und Vertragstext
- identisches anonymisiertes Testset mit gezielten Fehlerfällen

Intelligenter Modell-Router

1

1 · KLASSIFIZIEREN

Datenart, Sensibilität und Aufgabe bestimmen



2

2 · VERARBEITEN

Extraktion, Dokumentanalyse und Synthese
passend verteilen



3

3 · ABSICHERN

Bei Risiko eskalieren, gegenprüfen und Qualität
protokollieren

Beispielroute: Vertragsprüfung

01 HAIKU 4.5 / GPT-5.6 LUNA

OCR bereinigen, Seiten und Klauseln klassifizieren

02 SONNET 5 / GPT-5.6 TERRA

Dokument strukturieren, relevante Passagen extrahieren

03 GPT-5.6 SOL / OPUS 4.8

Risiken bewerten, Widersprüche erklären, Empfehlungen formulieren

04 FABLE 5 ODER ZWEITMODELL

Nur bei besonders komplexen oder kritischen Fällen

Übung: Router für eine KI-Anwendung

AUSGANGSLAGE

A

1. Eingabedaten und Tokenmenge
2. Qualitäts- und Sicherheitsanforderungen
3. Start- und Eskalationsmodell



ABSICHERUNG

B

4. messbare Eskalationskriterien
5. Fallback bei Fehlern
6. Testset und Erfolgsmetriken
7. menschliche Freigabepunkte

Aktuelle Produktquellen

ANBIETER-PRIMÄRQUELLE	VERWENDUNG
OpenAI: Latest model guide und Model Catalog	Modellnamen und Fähigkeiten
OpenAI API Pricing	Input-, Cache-, Output- und Toolpreise
Anthropic: Models overview	Modellklassen und Kontextgrenzen
Anthropic Pricing und Release Notes	Preise, Caching und Verfügbarkeit
Eigene API-Messungen	Tokenmenge, Latenz, Fehler und Gesamtkosten
Stand	17. Juli 2026 – vor jeder Kalkulation erneut prüfen

Technische Primärquellen

ORIGINALARBEIT	BEITRAG
Vaswani et al., 2017	Transformer-Architektur
Brown et al., 2020	Skalierung und Few-shot-Lernen
Kaplan et al., 2020	empirische Skalierungsgesetze
Hoffmann et al., 2022	Verhältnis von Modellgröße und Trainingsdaten
Ouyang et al., 2022	Instruction Tuning mit menschlichem Feedback
Liang et al., 2022: HELM	mehrdimensionale Modellevaluation